M2

一、 对 M1 意见的回应

问题 1：初始样本量不足，船型覆盖太窄
问题 2：全样本按大小分组会混淆船型与规模效应
问题 3：原始碳强度存在数量级异常值，会完全掩盖真实关系
问题 4：2023 年是 EEXI 实施首年，供应链紊乱的营运冲击可能污染结果。
针对以上问题已全部按照意见修改

二、 数据的获取说明

来源五问	欧洲海事安全局 THETIS-MRV
谁收集的	EMSATHETIS-MRV，由欧洲海事安全局发布，船位来自于 SafeSeaNet(SSN)系统提供的 AIS 数据。性质为[官]
怎样收集的	由航运公司依据实际航行与燃油记录填报
覆盖与偏差	覆盖：欧盟航线上 5000 总吨及以上货船与客船的 CO_2排放、燃油消耗及能效数据，按 EEA 港口间航程 100%、进出 EEA 航程 50%的规则计算。 偏差:只统计挂靠欧盟港口的船舶，与欧盟无关的航次和不挂靠欧盟的船不在样本内
口径	CO_2排放以千吨为单位，碳强度以 gCO2/吨 • 海里为单位，按日历年汇总
许可	公开排放数据可自由获取使用
已经下载了什么	下载了 THETIS-MRV2023 年的商船排放报告数据集。https://mrv.emsa.europa.eu
行数和字段	12829 行 IMO 编号；船舶类型；船名；年度总 CO_2 排放量；质量口径单位运输碳强度；Technicalefficiency

三、 清洗日志

#数据处理日志

##原始数据
来源：EMSATHETIS-MRV
文件：thrtis_mrv_2023
下载时间：2026.10.25

原始行数：12829 行

##清洗步骤

###步骤 1：筛选三种目标船型
操作：只保留 Shiptype 属于 Containership、Bulkcarrier、Oiltanker
删除前：12829 行
删除：5176 行
删除后：7653 行
理由：研究范围限定集装箱船、散货船、油船三种主力货运船型
各船型保留行数：
Containership:1928 行
Bulkcarrier:3796 行
Oiltanker:1929 行

###步骤 2：筛选有 EEXI 认证的船舶
操作：保留 Technicalefficiency 包含"EEXI"的记录，排除 EEDI/EIV/Not
删除前：7653 行
删除：3397 行
删除后：4256 行
理由：本研究核心自变量为 EEXI 设计能效值，无 EEXI 数据的船舶无法纳入分析
各船型含 EEXI 行数：
Containership:1482 行
Bulkcarrier:1785 行
Oiltanker:989 行

###步骤 3：提取碳强度并筛选非空/正值
操作：提取 co2_intensity 列为数值型，删除空值和≤0 的记录
co2_intensity 非空 4107 条，空值 149 条
co2_intensity≤0 的条数：1
删除前：4256 行
删除：150 行
删除后：4106 行
理由：碳强度是因变量 Y，缺失或非正值无法用于回归

###步骤 4：提取总 CO2 并筛选非空/正值
操作：提取 total_co2 列为数值型，删除空值和≤0 的记录
total_co2 非空 4106 条，空值 0 条
total_co2≤0 的条数：0
删除前：4106 行
删除：0 行
删除后：4106 行
理由：total_co2 是规模控制变量，缺失或非正值无法用于分组和回归

###步骤 5：正则提取 EEXI 数值并剔除异常值
操作：从 Technicalefficiency 列用正则提取 EEXI 括号内数值，删除≤0 的异常记录
eexi_value 解析成功 4106 条，失败 0 条
eexi_value≤0.0 的条数：1
被删除异常记录：IMO9490105（FITNES，散货船，EEXI 标注为 0，物理上不可能）
删除前：4106 行
删除：1 行
删除后：4105 行
理由：EEXI 为 0 的记录明显是数据错误，物理上不存在设计能效为 0 的船舶

###步骤 6：按船型做 1%/99%缩尾
操作：每种船型内部分别进行 1%和 99%分位缩尾，生成 co2_intensity_winsor 列
各船型缩尾阈值：
散货船：1%分位 2.939，99%分位 140.850，裁剪 34 条，最大值从 3802056.66 压缩到 140.850
集装箱船：1%分位 5.566，99%分位 117.555，裁剪 30 条，最大值从 7587.68 压缩到 117.555
油船：1%分位 3.492，99%分位 73.911，裁剪 20 条，最大值从 776.64 压缩到 73.911
缩尾前 co2_intensity 最大值：3802056.66
缩尾后 co2_intensity_winsor 最大值：140.85
删除前：4105 行，删除 0 行（仅截断数值），删除后：4105 行
理由：原始数据存在数量级异常值（散货船最大值达 380 万，明显录入错误），不处理会完全掩盖
真实回归关系。缩尾比直接删除更温和，保留全部样本量

###步骤 7：按 total_co2 全样本三分位生成 size_group
操作：全部 4105 艘船按 total_co2 从小到大等频切分为三组
各分组数量：
Small:1368 艘
Medium:1368 艘
Large:1369 艘
各分组 total_co2 范围：
Small:3.49~3950.18
Medium:3950.76~10215.56
Large:10219.51~92144.21
删除前：4105 行，删除 0 行（仅新增分组列），删除后：4105 行

###步骤 8：按船型内 total_co2 三分位生成 size_group_within_type
操作：每种船型内部各自按 total_co2 从小到大等频切分为三组
船型×分组交叉表：
集装箱船：Small493 艘/Medium493 艘/Large494 艘
散货船：Small562 艘/Medium562 艘/Large562 艘
油船：Small313 艘/Medium313 艘/Large313 艘
删除前：4105 行，删除 0 行（仅新增分组列），删除后：4105 行
理由：全样本三分位存在船型与规模混淆问题（Small 组 70%是散货船，Large 组 72%是集装箱船），船型内三分位可实现同类型船舶内部的大小对比

##最终样本
文件行数：4105，文件大小：358.63KB
最终样本量：4105
输出列：
imo,ship_name,ship_type,ship_type_group,report_year,co2_intensity,co2_intensity_winsor,total_co2,eexi_value,size_group,size_group_within_type

三个变量的均值、标准差、最小值、最大值：
co2_intensity_winsor：均值 17.40，标准差 18.45，最小值 2.94，最大值 140.85
total_co2：均值 10447.43，标准差 11461.89，最小值 3.49，最大值 92144.21
eexi_value：均值 7.88，标准差 6.22，最小值 1.65，最大值 35.14

分船型统计：
集装箱船（n=1480）：碳强度均值 26.52，EEXI 均值 14.31，总 CO_2 均值 18682.15
散货船（n=1686）：碳强度均值 12.08，EEXI 均值 4.36，总 CO_2 均值 4213.71
油船（n=939）：碳强度均值 12.57，EEXI 均值 4.06，总 CO_2 均值 8661.14

船型×船型内大小组均值：
集装箱船 Small：碳强度 33.75，EEXI15.60，总 CO_2 5241.30
集装箱船 Medium：碳强度 30.13，EEXI16.75，总 CO_2 14984.60
集装箱船 Large：碳强度 15.71，EEXI10.58，总 CO_2 35785.85
散货船 Small：碳强度 16.17，EEXI4.64，总 CO_2 1612.26
散货船 Medium：碳强度 10.69，EEXI4.40，总 CO_2 3558.97
散货船 Large：碳强度 9.39，EEXI4.04，总 CO_2 7469.91
油船 Small：碳强度 13.89，EEXI4.44，总 CO_2 3044.09
油船 Medium：碳强度 13.95，EEXI4.33，总 CO_2 7450.51
油船 Large：碳强度 9.86，EEXI3.41，总 CO_2 15488.81

##辅助数据构建（非建模用）
目的：为图 3 提供注册地坐标与分组汇总
输入：`ships_clean.csv`的`PortofRegistry`+UN/LOCODE（`data/raw/unlocode/`）
处理：港口名标准化→匹配坐标→剔除无坐标/不足 20 艘的组
输出：`data/explore/registry_map_ready.csv`（30 组/3,467 艘）

注册港连接、名称标准化、坐标匹配及分组汇总：
{
"ship_count":4105,
"registry_missing":88,
"coordinate_covered_ships":3664,
"pending_nonmissing_ships":353,
"ready_groups":30,
"ready_ships":3467,
"min_group_n":20,

"source_zip_sha256":"ecf6fcc57abcf5e567cb8d42f0de8dd621371b25b33fa5a730c16c4771cbfabb
"
}
sizesum
ship_type
Bulkcarrier111445
Containership101252
Oiltanker9770
一对一连接后保留 4105 艘，连接不删除船舶。
注册港缺失 88 艘；有注册港但名称或坐标待确认 353 艘；有坐标 3664 艘。
绘图表仅保留同船型同注册地至少 20 艘且有坐标的组合：30 组，覆盖 3467 艘。
注册港缺失及待确认观测保留在完整船舶表和核查表，不进行模糊猜测。
Madeira 使用 Funchal 代表点；Bridgetown 从 raw 中的坐标补充表读取；坐标不是排放位置。

四、 三张探索图

1.分布图

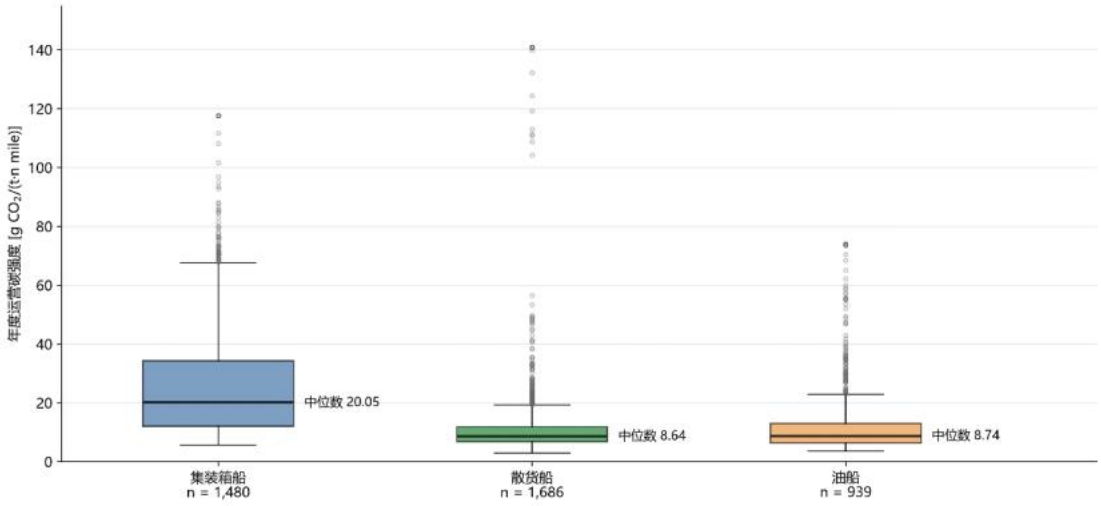


图 12023 年三种船型的运营碳强度分布

（1）数据来源：
欧洲海事安全局（EMSA）THETIS-MRV，2023 报告年度船舶排放数据〔官〕；本组下载日期为 2026 年 10 月 25 日，依据现有数据处理日志。
（2）关键参数：
仅保留集装箱船、散货船和油船中技术效率字段报告 EEXI，且运营碳强度、总 CO2 排放量和 EEXI 均为有效正值的记录；样本量 4,105 艘。使用按船型分别进行 1%和 99%分位缩尾后的碳强度。
（3）口径说明：
运营碳强度为年度单位质量运输功 CO2 排放量，单位为 gCO2 / （吨货物·海里），不等同于 AER。箱体为 Q1—Q3，中线为中位数；箱须延伸至距箱体不超过 1.5 倍 IQR 的最远实际观测，空心圆为箱须外观测。
集装箱船的碳强度中位数为 20.05，约为散货船（8.64）和油船（8.74）的 2.3 倍。其 IQR 为

22.27，明显高于散货船的 5.03 和油船的 6.63，说明集装箱船不仅典型碳强度较高，中间 50%样本的绝对差异也更大。散货船和油船的分布中心接近，但油船的主体分布更分散。
三类船均有向高碳强度方向延伸的尾部。集装箱船、散货船和油船的 P95 分别为 67.80、24.00 和 35.70，上侧离群点占比分别为 5.07%、8.54%和 10.33%。这些比例按各船型自己的 IQR 阈值计算，不代表超过同一碳强度标准的比例。数据已缩尾，图中最高点不能视为原始最大值。

2.关系图

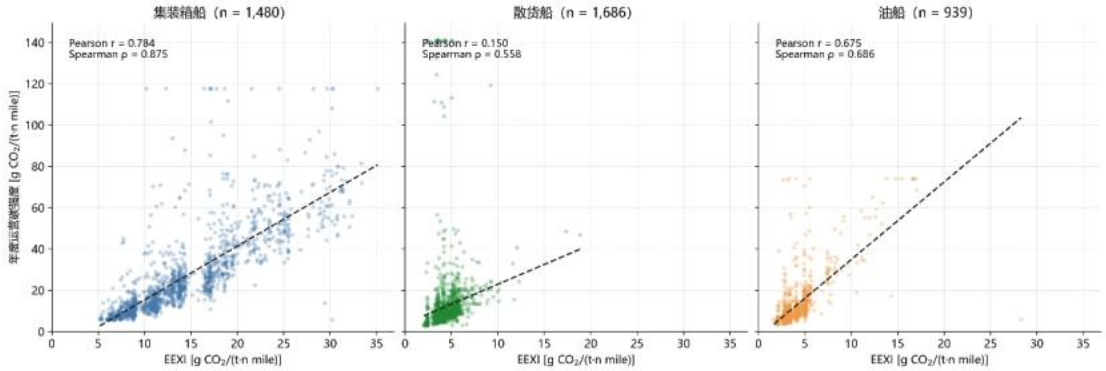


图 22023 年各船型 EEXI 与运营碳强度的关系

（1）数据来源：
EMSATHETIS-MRV，2023 报告年度船舶排放数据〔官〕；下载日期为 2026 年 10 月 25 日。
（2）关键参数：
沿用图 1 的 4,105 艘船和同一缩尾变量，按船型分别绘图，三个面板采用相同坐标范围。每点代表一艘船，虚线为带截距的一元最小二乘拟合线，仅覆盖该船型实际观测的 EEXI 范围。Pearson 系数衡量线性关联，Spearman 系数按平均秩计算，衡量单调关联。
（3）口径说明：
横轴为 EEXI，纵轴为质量运输功口径的年度运营碳强度，单位形式均为 gCO2 /（t·nmile），但 EEXI 的容量口径与运营指标的实际货物运输功口径不同，不能直接用两者相减衡量效率损失。图中关系属于同一报告年度的船舶间比较。

船型	样本量	Pearson r	Spearman ρ	一元线性拟合R^2
集装箱船	1,480	0.784	0.875	0.615
散货船	1,686	0.150	0.558	0.023
油船	939	0.675	0.686	0.455

三种船型的相关系数均为正，但关联强弱不同。集装箱船的线性关联最强，Pearson 系数为 0.784；油船次之，为 0.675。对应的一元线性拟合 R^2分别为 0.615 和 0.455，说明在当前样本及线性模型下，EEXI 分别能够解释约 61.5%和 45.5%的缩尾后运营碳强度变异。散货船的 Pearson 系数仅为 0.150，线性拟合 R^2约为 0.023，但 Spearman 系数为 0.558。这表明散货船仍存在一定的正向单调关联，只是简单直线不能充分概括，可能还受到非线性、高值观测及其他分组差异影响。这些结果均未控制规模、载货率、航速等因素，R^2只表示样本内的一元线性拟合程度，不是 EEXI 独立造成的影响，也不代表样本外预测能力。

3.空间图

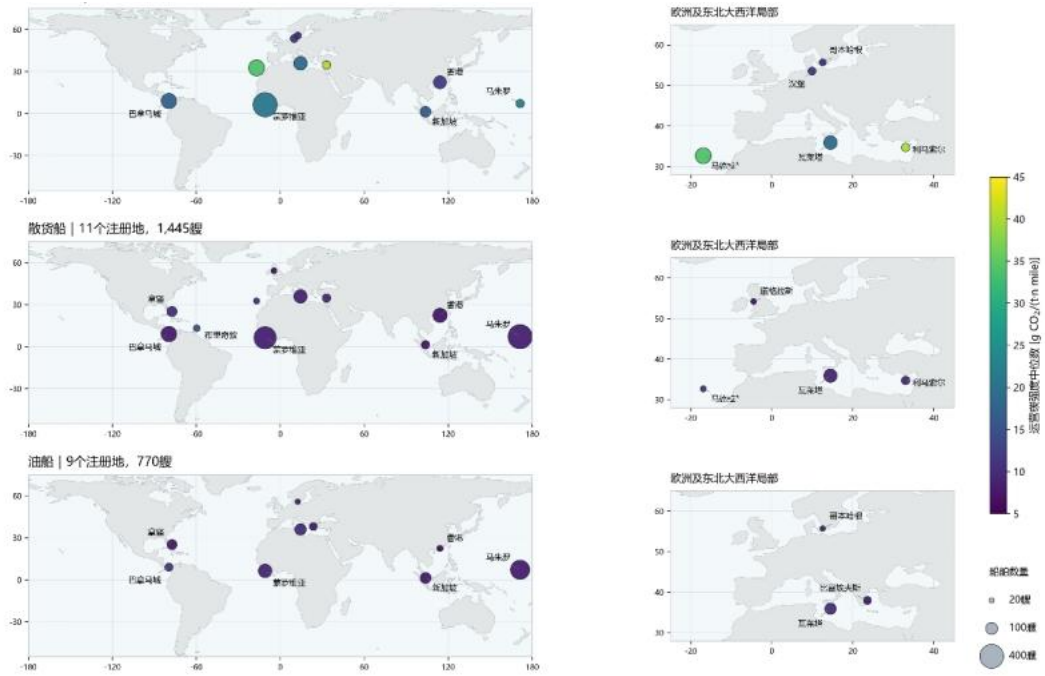


图 32023 年不同船型船舶的注册地与运营碳强度

（1）数据来源：

辅助数据 UN/LOCODE；船舶指标及注册港来自 EMSATHETIS-MRV，地点坐标主要来自 UNECEUN/LOCODE 官方预发布目录，Bridgetown 坐标补充自 BarbadosPortInc.港口资料；坐标和底图为位置参照，不是 2023 年船舶轨迹。

（2）关键参数：

通过 IMO 编号将 4,105 艘清洗样本与原表注册港一对一连接，统一已核实的名称写法。仅展示同一船型、同一注册地至少 20 艘且有坐标的组合，共 30 组、3,467 艘：集装箱船 10 组 1,252 艘、散货船 11 组 1,445 艘、油船 9 组 770 艘。未展示的 638 艘包括 88 艘注册港缺失、353 艘名称或坐标待确认，以及 197 艘已定位但所在船型—注册地组不足 20 艘的记录。

（3）口径说明：

颜色为组内缩尾后运营碳强度中位数，单位为 gCO2 /（吨货物·海里）；圆点面积与船舶数量成正比，各面板共用色标和面积比例。中位数按船舶等权计算，不是区域运输功加权碳强度。位置仅表示注册地，不代表船东国籍、航线或实际排放位置；Madeira 使用 Funchal 代表点。右侧为左侧部分地点的放大展示，不增加样本量。地图采用等经纬度示意。集装箱船在不同注册地之间的碳强度差异较大。利马索尔和马德拉的中位数分别为 40.33 和 33.99，高于哥本哈根的 9.77、汉堡的 11.38 和香港的 11.77。蒙罗维亚的集装箱船样本最多，为 409 艘，其中位数为 21.08，说明样本数量较多不意味着碳强度更高。散货船和油船在已展示注册地之间的差异小于集装箱船。散货船中位数介于 6.64—14.98，布里奇敦相对较高；油船介于 5.99—11.30。两类船的样本均较集中于马朱罗和蒙罗维亚。

五、 这份数据不能回答什么

1.覆盖方面

因为该数据只统计挂靠欧盟港口（EEA 港口间航程按 100%、进出 EEA 航程按 50%计入）的 500 总吨及以上货船与客船，与欧盟无关的航次和不挂靠欧盟港口的船舶完全不在样

本内，且清洗后仅保留集装箱船、散货船、油船三类船型中有 EEXI 认证记录的 4,105 艘船，所以不能回答"全球航运业或非欧盟航线船舶的 EEXI 与运营碳强度关系如何""未挂靠欧盟港口的小型船舶、其他船型（如杂货船、滚装船、客船）的碳强度分布与 EEXI 关联是否同样成立""某船东旗下全部船队（含非欧盟航线运力）的整体能效表现"等问题。

2.时间方面

因为数据仅为 2023 年单一日历年的截面汇总，而 2023 年是 EEXI 实施首年，供应链紊乱等营运冲击可能污染当年结果，且清洗日志只按日历年汇总、无跨年面板，所以不能回答"EEXI 实施后船舶碳强度是否逐年下降""EEXI 认证对运营碳强度的因果效应随时间如何演变""2024 年及以后合规调整后 EEXI 与碳强度的关系是否稳定""某艘船在 2023 年之前与之后的碳强度对比"等需要多期数据或因果识别的问题。

3.口径方面

因为碳强度是按"单位质量运输功"计算的年度运营指标（gCO2/吨·海里），而 EEXI 是设计能效值，两者容量口径与实际货物运输功口径不同、不能直接相减衡量效率损失；同时数据未控制规模、载货率、航速、航线、船龄等因素，注册地坐标也只代表注册港而非实际航线或排放位置，所以不能回答"某船 EEXI 达标是否意味着其实际运营效率损失为零""EEXI 独立造成多少碳强度变化（因果效应）""船舶在具体航次或具体海域的实际排放强度是多少""注册地碳强度差异是否由船东国籍或实际运营区域造成"等问题。

六、 组内互评

邓静彤

作为组长，项目节奏把握得很稳，遇到选题调整时能快速把大家的分工重新对齐，不让进度悬空。技术上是组里投入最多的，数据清洗和回归结果都做了交叉核对，代码和复现包整理得比较清楚，别人照着 README 基本能跑通。协作时愿意听意见，讨论方案不会只坚持自己那一套。建议以后可以更早把技术口径同步给写作和 PPT 的同学，减少后期反复解释的成本。

谭敏

报告写得扎实，能把分散的回归结果和图表串成一条完整的论证线，章节之间的过渡比较自然。对研究边界、数据伦理和误用风险的讨论不是套话，能看出确实想过这些问题。文字上偶尔有长句和重复表述，建议定稿前再通读一遍，统一术语（尤其是 R^2 的几种口径）和图表编号。

王晗琪

开题和路演 PPT 都完成得比较利落，5 页里把问题、方法、核心结论讲清楚了，没有堆数字，版式也干净。建议路演前多准备几个数据口径类的问题，比如“为什么 R^2 有三种”“为什么散货船这么低”，回答会更从容。

陈文雅婷

四张图的完成度很高，配色统一、图注规范，空间地图尤其能看出花了心思。README 和数据字段字典写得很清楚，确实降低了别人复现的门槛。建议图上再补一些关键统计量（如 R^2 、n、显著性标记），让图本身更自解释，减少对正文的依赖。